FATEC OURINHOS

CIÊNCIA DE DADOS

ALBERTO TOTI JOSÉ

GUSTAVO DE SOUZA RAMOS

MAICON FRANCISCO SOARES

VINICIUS WOICIKIEVIZ CHOMA

PROCESSAMENTO DE LINGUAGEM NATURAL: APLICAÇÃO DE TÉCNICAS DE VETORIZAÇÃO DE TEXTO EM UM CORPUS DE POEMAS DE LÍNGA PORTUGUESA.

Trabalho apresentado como requisito de avaliação da disciplina de Processamento de Linguagem Natural, ministrada pelo(a) Professor(a) Alex Mariano Gonçalves de Almeida.

OURINHOS

2026

SUMÁRIO

Conteúdo

1. INTRODUÇÃO....3
2. METODOLOGIA....3
3. RESULTADOS....4
3.1 Análise exploratória inicial....4
3.2.1 Eficiência quantitativa da remoção de stopwords....5
3.2.1 Distribuição de tokens....5
3.3 Análise de frequência dos termos....6
3.4.1 Comparação entre autores selecionados....6
3.4.2 Word Cloud TF vs TF-IDF....8
3.5 Análises de similaridade entre poemas....9
4. DISCUSSÃO....9
4.1 Interpretação dos resultados....9
4.2 Comparação entre TF e TF-IDF....9
4.3 Aplicação de stemming e lematização....9
4.4 Limitações do estudo....9
4.4 Implicações práticas....10
5. CONCLUSÃO....11

1. INTRODUÇÃO

O avanço das técnicas de Processamento de Linguagem Natural (PLN) tem possibilitado a análise automática de grandes volumes de textos. Entre as diversas aplicações dessa área, destaca-se a análise de obras literárias, permitindo identificar padrões linguísticos, temas recorrentes e características estilísticas de diferentes autores.

Neste trabalho foi utilizado um conjunto de dados contendo poemas em língua portuguesa, com o objetivo de explorar padrões linguísticos presentes no corpus. A análise buscou comparar estilos entre autores e identificar termos relevantes nos textos utilizando técnicas de mineração de texto.

Para isso, foram aplicadas técnicas de pré-processamento textual e métodos de representação vetorial, como *Term Frequency* (TF) e *Term Frequency–Inverse Document Frequency* (TF-IDF). Além disso, foram utilizadas técnicas de stemming e lematização para normalização das palavras. Os resultados foram explorados por meio de análises estatísticas e visualizações gráficas.

2. METODOLOGIA

O processo de análise foi dividido em diversas etapas, iniciando pela preparação do conjunto de dados. O dataset utilizado contém milhares de poemas escritos por diferentes autores da literatura em língua portuguesa. Inicialmente foi realizada uma análise exploratória para compreender a estrutura dos dados, verificar valores nulos e identificar a distribuição de poemas por autor.

Em seguida, foram selecionados três autores específicos para análise comparativa: Fernando Pessoa, Angela Santos e Sophia de Mello Breyner Andresen. Essa seleção foi realizada para reduzir o impacto do desbalanceamento do dataset, já que alguns autores possuem um número muito maior de poemas do que outros.

Após essa etapa, foi realizado o pré-processamento textual, que incluiu:

- conversão do texto para letras minúsculas
- remoção de pontuação e números
- “tokenização” das palavras
- remoção de *stopwords* da língua portuguesa

Posteriormente foram aplicadas técnicas de normalização morfológica. O *stemming*, utilizando o algoritmo RSLP, reduz palavras ao seu radical, enquanto a lematização, realizada com a biblioteca spaCy, transforma as palavras em sua forma base ou lema.

Para representar os textos numericamente, foram utilizadas duas abordagens principais:

- TF (*Term Frequency*), que contabiliza a frequência de ocorrência das palavras no corpus
- TF-IDF, que pondera a frequência das palavras considerando sua raridade nos documentos

Essas representações vetoriais permitiram identificar palavras mais relevantes nos poemas. Além disso, foi utilizada a similaridade do cosseno para medir a proximidade semântica entre diferentes poemas.

Por fim, os resultados foram visualizados por meio de gráficos de frequência e *word clouds*, facilitando a interpretação dos padrões encontrados.

3. RESULTADOS

3.1 Análise exploratória inicial

O *dataset* contém uma grande quantidade de poemas distribuídos entre diversos autores. Entretanto, observou-se uma forte concentração de textos em alguns autores específicos, indicando um desbalanceamento na distribuição.

Imagem 1 – Top 15 Autores com mais poemas no dataset

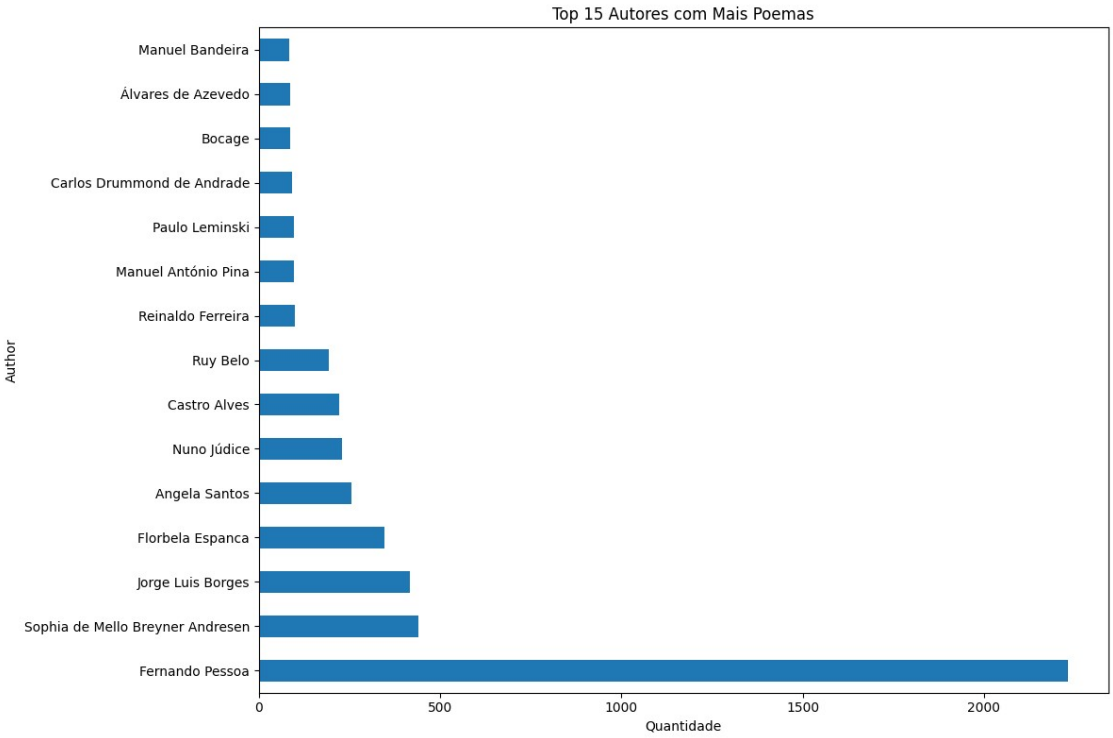

Fonte: Elaborado pelo autor (2026).

3.2.1 Eficiência quantitativa da remoção de *stopwords*

A aplicação da etapa de remoção de *stopwords* resultou em uma redução significativa do número de *tokens* no corpus analisado. O poema inicialmente apresentava em média 123.99 *tokens*, sendo reduzido para 60.75 *tokens* após o pré-processamento, o que corresponde a uma taxa de redução de 51%.

Observou-se que a maior parte dos termos removidos correspondia a palavras de função gramatical, como artigos, preposições e conjunções. Após a filtragem, permaneceram predominantemente termos com maior carga semântica, como substantivos, adjetivos e verbos

3.2.1 Distribuição de *tokens*

Após o processo de limpeza textual e remoção de stopwords, houve uma redução significativa na quantidade de tokens presentes nos textos. Esse processo permitiu eliminar palavras muito comuns da língua portuguesa, como artigos e preposições, que normalmente não contribuem para a identificação de temas ou estilos literários.

Imagem 2 – Distribuição de *Tokens* por poema após a limpeza

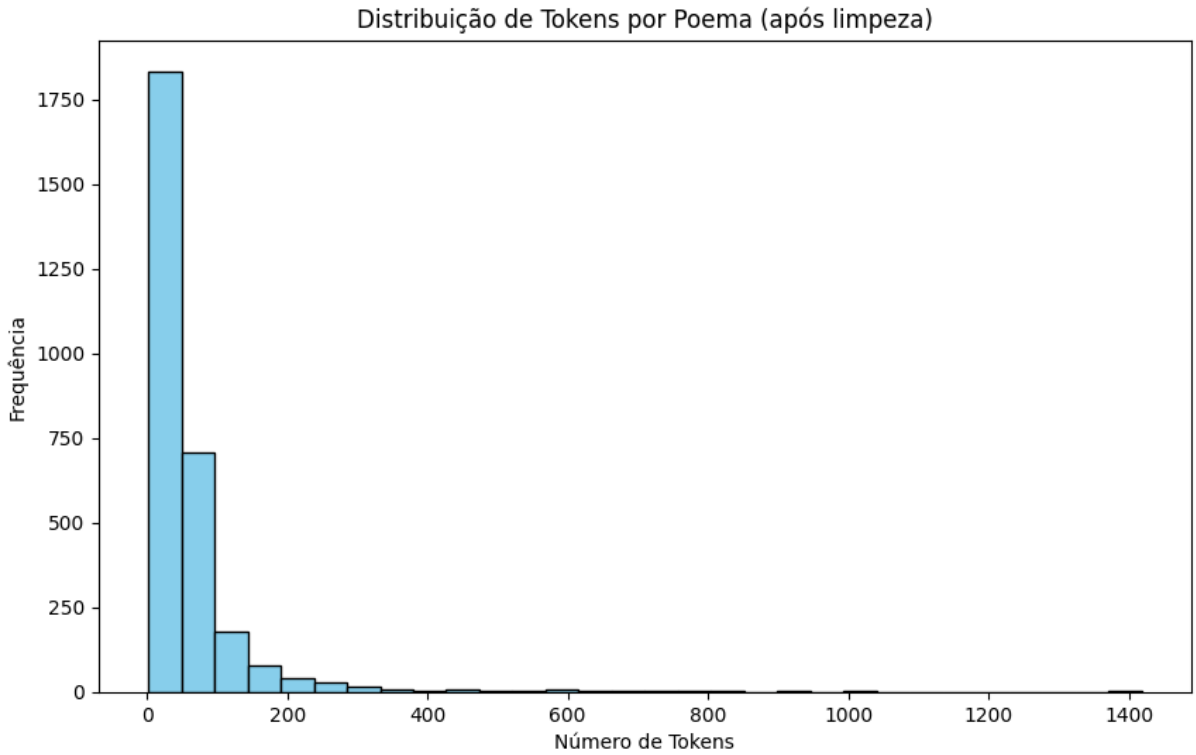

Fonte: Elaborado pelo autor (2026).

A **Imagem 2** demonstra que a maioria dos poemas possui entre 20 e 100 *tokens* após o pré-processamento. A distribuição apresenta uma assimetria positiva, contendo alguns poemas longos que ultrapassam 1000 *tokens*. Justificando o uso de técnicas como TF-IDF para normalizar o impacto de documentos maiores nas análises de frequência.

3.3 Análise de frequência dos termos

A análise de frequência dos termos normalizados permitiu identificar os elementos mais recorrentes no corpus.

Imagem 3 – Top 20 termos mais frequentes

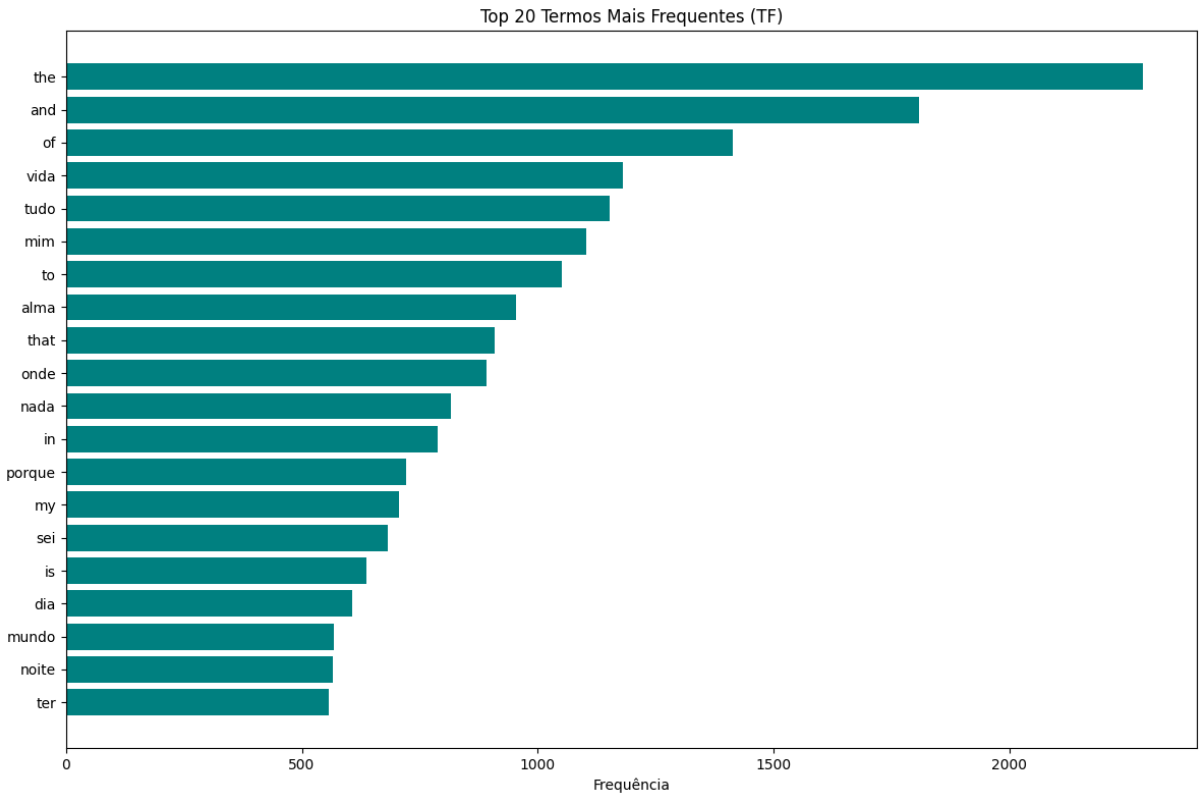

Fonte: Elaborado pelo autor (2026).

Observou-se forte presença de palavras funcionais da língua inglesa, como “the”, “and” e “of”, indicando que o corpus contém poemas multilíngues ou traduzidos. Esse fator introduz ruído na análise, podendo comprometer a interpretação dos padrões linguísticos.

Ainda assim, termos como “vida”, “alma” e “mundo” aparecem com alta frequência, sugerindo que os poemas abordam temas existenciais e subjetivos, característicos da poesia lírica.

3.4.1 Comparação entre autores selecionados

A comparação entre os autores analisados mostrou diferenças interessantes na escolha de vocabulário e nos temas predominantes em seus poemas. Alguns autores apresentaram maior recorrência de termos relacionados a emoções e introspecção, enquanto outros utilizaram vocabulário mais associado a elementos da natureza ou reflexões existenciais.

Imagem 4 – Nuvem de palavras – Fernando Pessoa

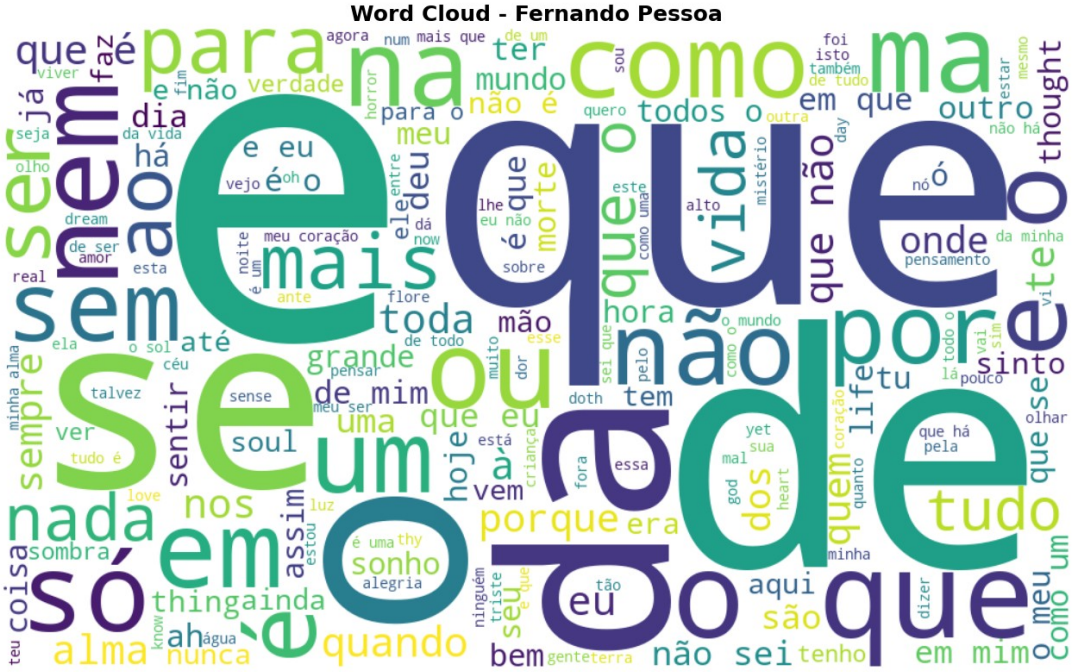
Word Cloud - Fernando Pessoa
e
que
se
de
o
na
como
ma
para
sem
ser
nem
mais
ou
um
não
por
vida
tudo
nada
em
só
quando
porque
sonho
alma
nunca
thingainda
ah
eu
bem
não sei
aqui
são
tenho
em mim
onde
toda
mão
hora
sinto
sentir
soul
nos
assim
hoje
vem
dos
quem
que não
todos
outro
em que
thought
verdade
dia
meu
morte
grande
de mim
uma
que eu
tem
doth
life
tu
pensamento
meu coração
meu ser
talvez
sense
pensar
sempre
ver
tudo é
até
céu
sol
ela
minha alma
sombra
coisa
teu
love
know
água
alegria
triste
ninguém
gente
terra
criança
está
à
fora
essa
yet
sua
mal
god
heart
quanto
coração
que há
pela
olhar
todo o
vai
sim
pouco
lá
como o mundo
esse
muito
dor
pelo
sei que
como uma
este
alto
mistério
day
não há
nó
ó
estar
mesmo
outra
quero
sou
horror
viver
faz
já
seja
olho
dream
de ser
amor
esta
real
da vida
há
vejo
oh
entre
ele
dá
now
lhe
eu não
sobre
meu
ante
flore
noite
é um
de todo
dizer
minha
estou
é uma
thy
luz
tão
seu
que
é
água
nunca
alegria
terra
gente
tenho
em mim
como
um
meu
o
vite
se
sinto
olhar
que
que há
pela
da minha
pensamento
da vida
de um
num
mais que
agora
foi
isto
também
de tudo
mesmo
estar
não há
day
outra
sou
horror
viver
faz
já
seja
olho
dream
de ser
amor
esta
real
meu coração
noite
é um
ante
flore
de todo
muito
dor
sei que
como o mundo
esse
pelo
como uma
este
alto
mistério
day
não há
nó
ó
estar
mesmo
outra
quero

Imagem 6 – Nuvem de palavras – Sophia de Mello

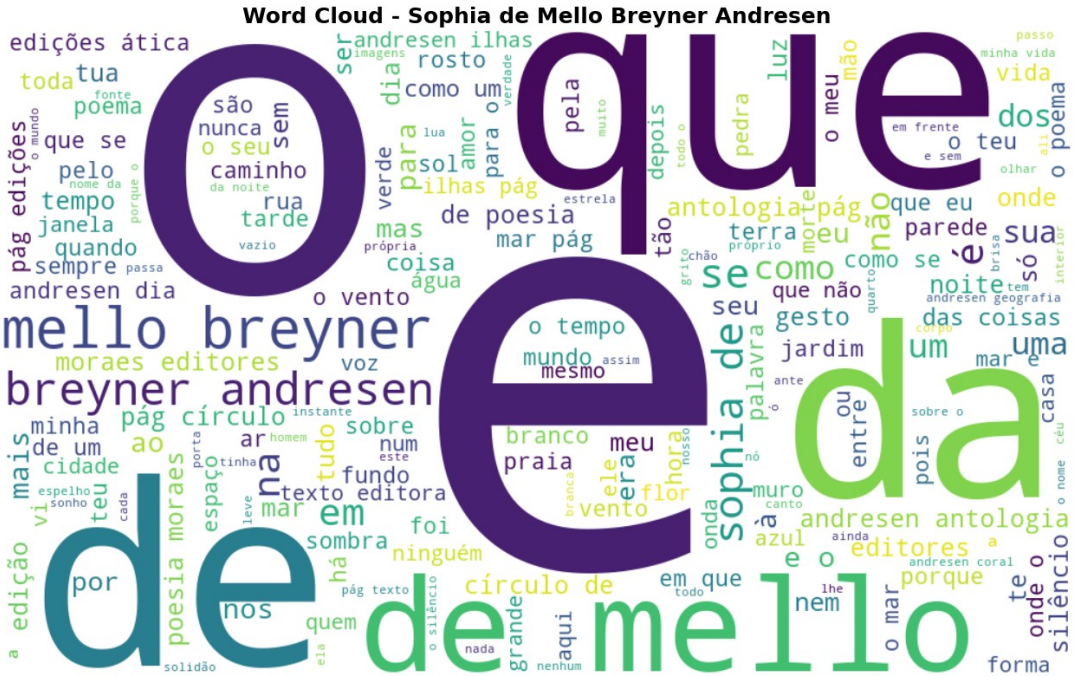

Fonte: Elaborado pelo autor (2026).

Além disso, a visualização por meio de *wordclouds*, como demonstrados nas **Imagem 4, 5 e 6** permitiu identificar visualmente as palavras mais presentes nos textos de cada autor. Nessas visualizações, o tamanho das palavras é proporcional à sua frequência ou relevância, facilitando a identificação de padrões linguísticos.

3.4.2 Word Cloud TF vs TF-IDF

Afim de uma comparação entre TF e TF-IDF foi selecionado o autor Fernando Pessoa para criação de um word cloud com os dados de seus poemas.

Imagem 7 – Nuvem de palavras TF x TF-IDF

TF - Fernando Pessoa
que
o
de
e
da
na
se
sem
não
como
mais
tudo
ao
um
ser
nada
nem
por
em
ou
ma
assim não sei
TF-IDF - Fernando Pessoa
the
tudo
vida
onde
coração
dia
mim
porque
nada
ter
alma
olhos
deus
amor
céu
mundo
coisas
horror
deuses
pensamento
fazer
sinto
sempre
ninguém
of
mar
quero
todos
bem
cada
sentir
ver
flores
água
toda
ah
morte
grande
aqui
vem
dentro
talvez
mistério
frio
pensar
viver
poder
razão
estrada
sombra
tão
triste
noite
sonho
alguém
dizer
fim
hoje
todas
verdade
melhor
outros
pouco
vento
terra
sono
consciência
universo
sabe
mão
meu ser
criança
estar
são
mistério
horror
deuses
pensamento
fazer
ah
toda
coisas
nada
porque
alma
todos
bem
ter
céu
cada
sentir
ver
flores
água
morte
grande
aqui
vem
dentro
talvez
viver
poder
razão
estrada
sombra
tão
triste
noite
sonho
alguém
dizer
fim
hoje
todas
verdade
melhor
outros
pouco
vento
terra
sono
consciência
universo
sabe
mão
mistério
frio
céu
cada
sentir
ver
flores
água
toda
ah

comuns. Dessa forma, TF revela popularidade de termos, enquanto TF-IDF revela relevância contextual.

3.5 Análises de similaridade entre poemas

Utilizando a similaridade do cosseno aplicada aos vetores TF-IDF, permitiu identificar poemas semanticamente próximos dentro do corpus. Essa abordagem demonstrou que textos com vocabulário semelhante tendem a apresentar maior proximidade no espaço vetorial.

4. DISCUSSÃO

4.1 Interpretação dos resultados

Os resultados obtidos demonstram que técnicas de Processamento de Linguagem Natural podem ser utilizadas de forma eficaz para explorar padrões linguísticos em textos literários. Mesmo em um corpus composto por poemas, que frequentemente apresentam linguagem figurada e estruturas não convencionais, foi possível identificar tendências e diferenças estilísticas entre autores.

4.2 Comparação entre TF e TF-IDF

A comparação entre **TF e TF-IDF** mostrou diferenças importantes na interpretação dos dados. Enquanto o TF destaca palavras mais frequentes no corpus, o TF-IDF consegue identificar termos mais distintivos de determinados poemas ou autores, proporcionando uma visão mais aprofundada do conteúdo semântico.

4.3 Aplicação de stemming e lematização

A aplicação das técnicas mostrou impactos relevantes na análise textual. O stemming facilita a redução de variações morfológicas, mas pode gerar radicais que não correspondem a palavras reais da língua. Já a lematização preserva formas linguísticas válidas, tornando os resultados mais interpretáveis.

4.4 Limitações do estudo

O estudo apresentou limitações relacionadas às ferramentas e ao próprio corpus analisado. No caso da biblioteca NLTK, observou-se limitação no suporte a modelos adequados para a língua portuguesa, o que comprometeu a precisão em tarefas de classificação gramatical. Esse resultado evidencia a dependência de modelos específicos para cada idioma, sendo inadequado o uso de modelos treinados em contextos linguísticos distintos.

Outra limitação identificada se refere à composição do conjunto de dados, no qual foram encontrados termos em diferentes idiomas, sem separação prévia. Esse fator pode ter influenciado os resultados de frequência e comprometido parcialmente a análise.

Outro aspecto importante observado foi o desbalanceamento do dataset. Autores com maior quantidade de poemas tendem a influenciar mais as estatísticas globais do corpus. Por esse motivo, a seleção de autores específicos para análise comparativa foi uma estratégia importante para reduzir esse efeito.

4.4 Implicações práticas

Os achados deste estudo possuem implicações relevantes para o desenvolvimento de aplicações em Processamento de Linguagem Natural. A escolha da técnica de normalização deve considerar o objetivo da aplicação, equilibrando desempenho e precisão linguística.

Em cenários que demandam rapidez e processamento de grandes volumes de dados, o uso de *stemming* pode ser mais adequado. Por outro lado, aplicações que exigem maior interpretação semântica, como sistemas de recomendação, análise de sentimentos ou *chatbots*, tendem a se beneficiar do uso de lematização.

Além disso, os resultados reforçam a importância da etapa de pré-processamento como fator determinante para a qualidade das análises, destacando a necessidade de adequação das ferramentas ao idioma e ao tipo de corpus utilizado.

5. CONCLUSÃO

Este trabalho demonstrou a aplicação de técnicas de Processamento de Linguagem Natural na análise de poemas em língua portuguesa. A partir do uso de métodos de pré-processamento, vetorização textual e análise estatística, foi possível explorar padrões linguísticos presentes no corpus e identificar diferenças estilísticas entre autores.

As técnicas de TF e TF-IDF mostraram-se eficazes para identificar termos relevantes nos textos, enquanto as etapas de *stemming* e *lematização* contribuíram para a normalização das palavras e melhoria da análise textual.

Além disso, o uso de visualizações como *wordclouds* e a análise de similaridade entre poemas permitiram interpretar os resultados de forma mais intuitiva.

Como aprendizado principal, o trabalho evidencia que técnicas de mineração de texto podem ser aplicadas não apenas em documentos informativos, mas também em textos literários, oferecendo novas perspectivas para a análise de obras e estilos de diferentes autores.