FATEC OURINHOS

CIÊNCIA DE DADOS

ALBERTO TOTI JOSÉ

GUSTAVO DE SOUZA RAMOS

MAICON FRANCISCO SOARES

VINICIUS WOICIKIEVIZ CHOMA

PROCESSAMENTO DE LINGUAGEM NATURAL: APLICAÇÃO DE TÉCNICAS DE VETORIZAÇÃO DE TEXTO EM UM CORPUS DE POEMAS DE LÍNGA PORTUGUESA.

Trabalho apresentado como requisito de avaliação da disciplina de Processamento de Linguagem Natural, ministrada pelo(a) Professor(a) Alex Mariano Gonçalves de Almeida.

OURINHOS

2026

SUMÁRIO

Conteúdo

1. INTRODUÇÃO.....3
2. METODOLOGIA.....3
3. RESULTADOS.....4
3.1 Análise exploratória inicial.....4
3.2.1 Eficiência quantitativa da remoção de *stopwords*.....5
3.2.2 Distribuição de *tokens*.....5
3.3.1 Análise de frequência dos termos.....5
3.3.2 Análise de importância dos termos.....7
3.4.1 Comparação entre autores selecionados.....9
3.4.2 *WordCloud* TF vs TF-IDF.....11
3.5 Análises de similaridade entre poemas.....12
4. DISCUSSÃO.....13
4.1 Interpretação dos resultados.....13
4.2 Comparação entre TF e TF-IDF.....13
4.3 Aplicação de *stemming* e lematização.....13
4.4 Limitações do estudo.....13
4.4 Implicações práticas.....13
5. CONCLUSÃO.....15

1. INTRODUÇÃO

O avanço das técnicas de Processamento de Linguagem Natural (PLN) tem possibilitado a análise automática de grandes volumes de textos. Entre as diversas aplicações dessa área, destaca-se a análise de obras literárias, permitindo identificar padrões linguísticos, temas recorrentes e características estilísticas de diferentes autores.

Neste trabalho foi utilizado um conjunto de dados contendo poemas em língua portuguesa, com o objetivo de explorar padrões linguísticos presentes no corpus. A análise buscou comparar estilos entre autores e identificar termos relevantes nos textos utilizando técnicas de mineração de texto.

Para isso, foram aplicadas técnicas de pré-processamento textual e métodos de representação vetorial, como Term Frequency (TF) e Term Frequency–Inverse Document Frequency (TF-IDF). Além disso, foram utilizadas técnicas de stemming e lematização para normalização das palavras. Os resultados foram explorados por meio de análises estatísticas e visualizações gráficas.

2. METODOLOGIA

O processo de análise foi dividido em diversas etapas, iniciando pela preparação do conjunto de dados. O *dataset* utilizado contém 15.541 de poemas escritos por diferentes autores. Inicialmente foi realizada uma análise exploratória para compreender a estrutura dos dados, verificar valores nulos e identificar a distribuição de poemas por autor.

Em seguida, foram selecionados três autores específicos para análise comparativa: Fernando Pessoa, Florbela Espanca e Sophia de Mello Breyner Andresen. Foram selecionados 340 poemas de cada autor, balanceando o conjunto de dados e possibilitando uma melhor análise entre autores.

Após essa etapa, foi realizado o pré-processamento textual, que incluiu:

- remoção de texto em línguas estrangeiras
- conversão do texto para letras minúsculas
- remoção de pontuação e números
- tokenização das palavras
- remoção de *stopwords* da língua portuguesa

Posteriormente foram aplicadas técnicas de normalização morfológica. O *stemming*, utilizando o algoritmo RSLP, reduz palavras ao seu radical, enquanto a lematização, realizada com a biblioteca spaCy, transforma as palavras em sua forma base ou lema.

Para representar os textos numericamente, foram utilizadas duas abordagens principais:

- TF (Term Frequency), que contabiliza a frequência de ocorrência das palavras no corpus
- TF-IDF, que pondera a frequência das palavras considerando sua raridade nos documentos

Essas representações vetoriais permitiram identificar palavras mais relevantes nos poemas. Além disso, foi utilizada a similaridade do cosseno para medir a proximidade semântica entre diferentes poemas.

Por fim, os resultados foram visualizados por meio de gráficos de frequência e word clouds, facilitando a interpretação dos padrões encontrados.

3. RESULTADOS

3.1 Análise exploratória inicial

O *dataset* contém uma grande quantidade de poemas distribuídos entre diversos autores. Entretanto, observou-se uma forte concentração de textos em alguns autores específicos, indicando um desbalanceamento na distribuição.

Imagem 1 – Top 15 Autores com mais poemas no dataset

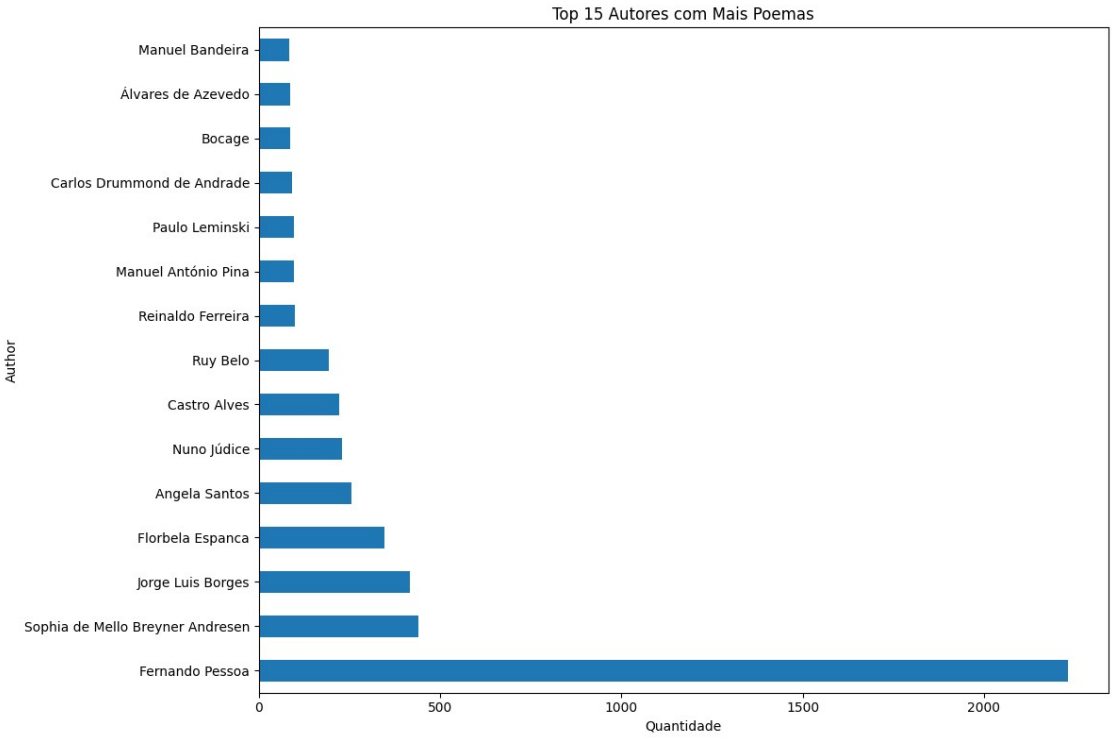

Fonte: Elaborado pelo autor (2026).

3.2.1 Eficiência quantitativa da remoção de *stopwords*

A aplicação da etapa de remoção de *stopwords* resultou em uma redução significativa do número de *tokens* no corpus analisado. Os poemas inicialmente apresentavam em média 97.75 *tokens*, sendo reduzido para 45.51 *tokens* após o pré-processamento, o que corresponde a uma taxa de redução de 53.45%.

Observou-se que a mais da metade dos termos correspondiam a palavras de função gramatical, como artigos, preposições e conjunções. Após a filtragem, permaneceram predominantemente termos com maior carga semântica, como substantivos, adjetivos e verbos.

3.2.2 Distribuição de *tokens*

A **Imagem 2** demonstra que a maioria dos poemas possui entre 20 e 100 *tokens* após o pré-processamento. A distribuição apresenta uma assimetria positiva, contendo alguns poemas longos que ultrapassam 600 *tokens*. Justificando o uso de técnicas como TF-IDF para normalizar o impacto de documentos maiores nas análises de frequência.

.

Imagem 2 – Distribuição de Tokens por poema após a limpeza

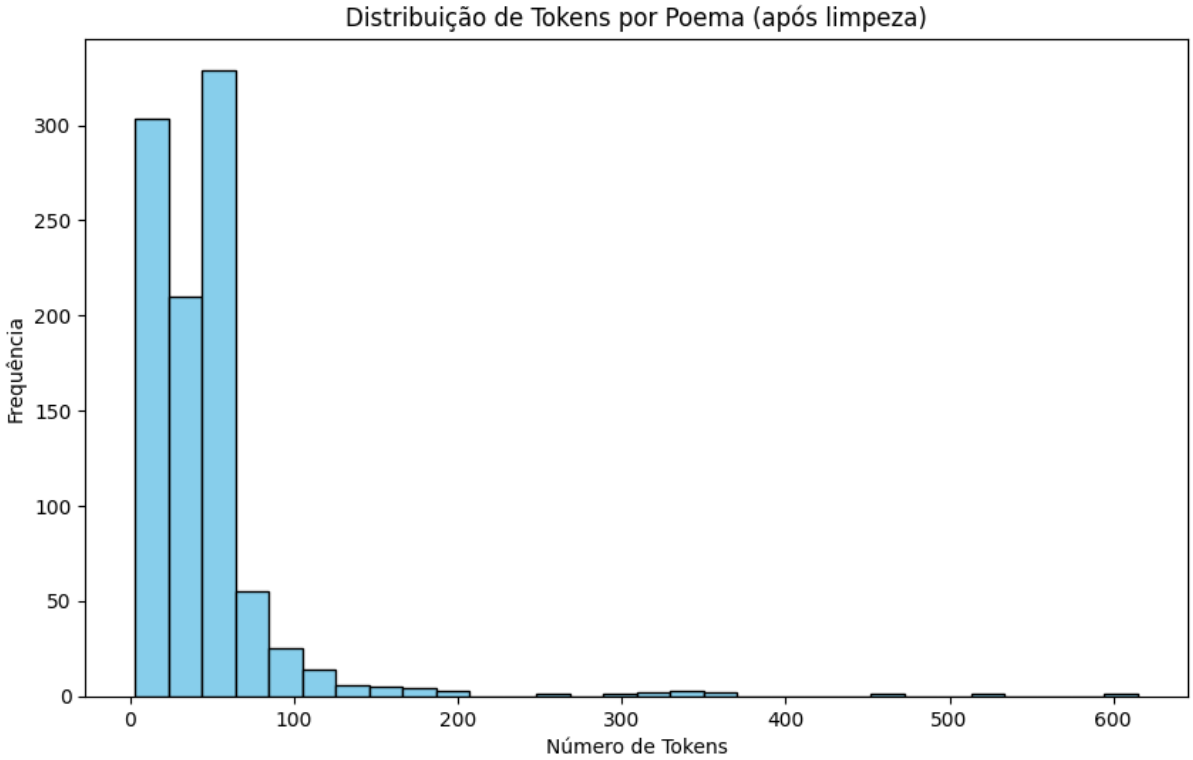

Fonte: Elaborado pelo autor (2026).

3.3.1 Análise de frequência dos termos

A análise de frequência dos termos normalizados permitiu identificar os elementos mais recorrentes no corpus.

Imagem 3 – Top 10 termos mais frequentes por autor

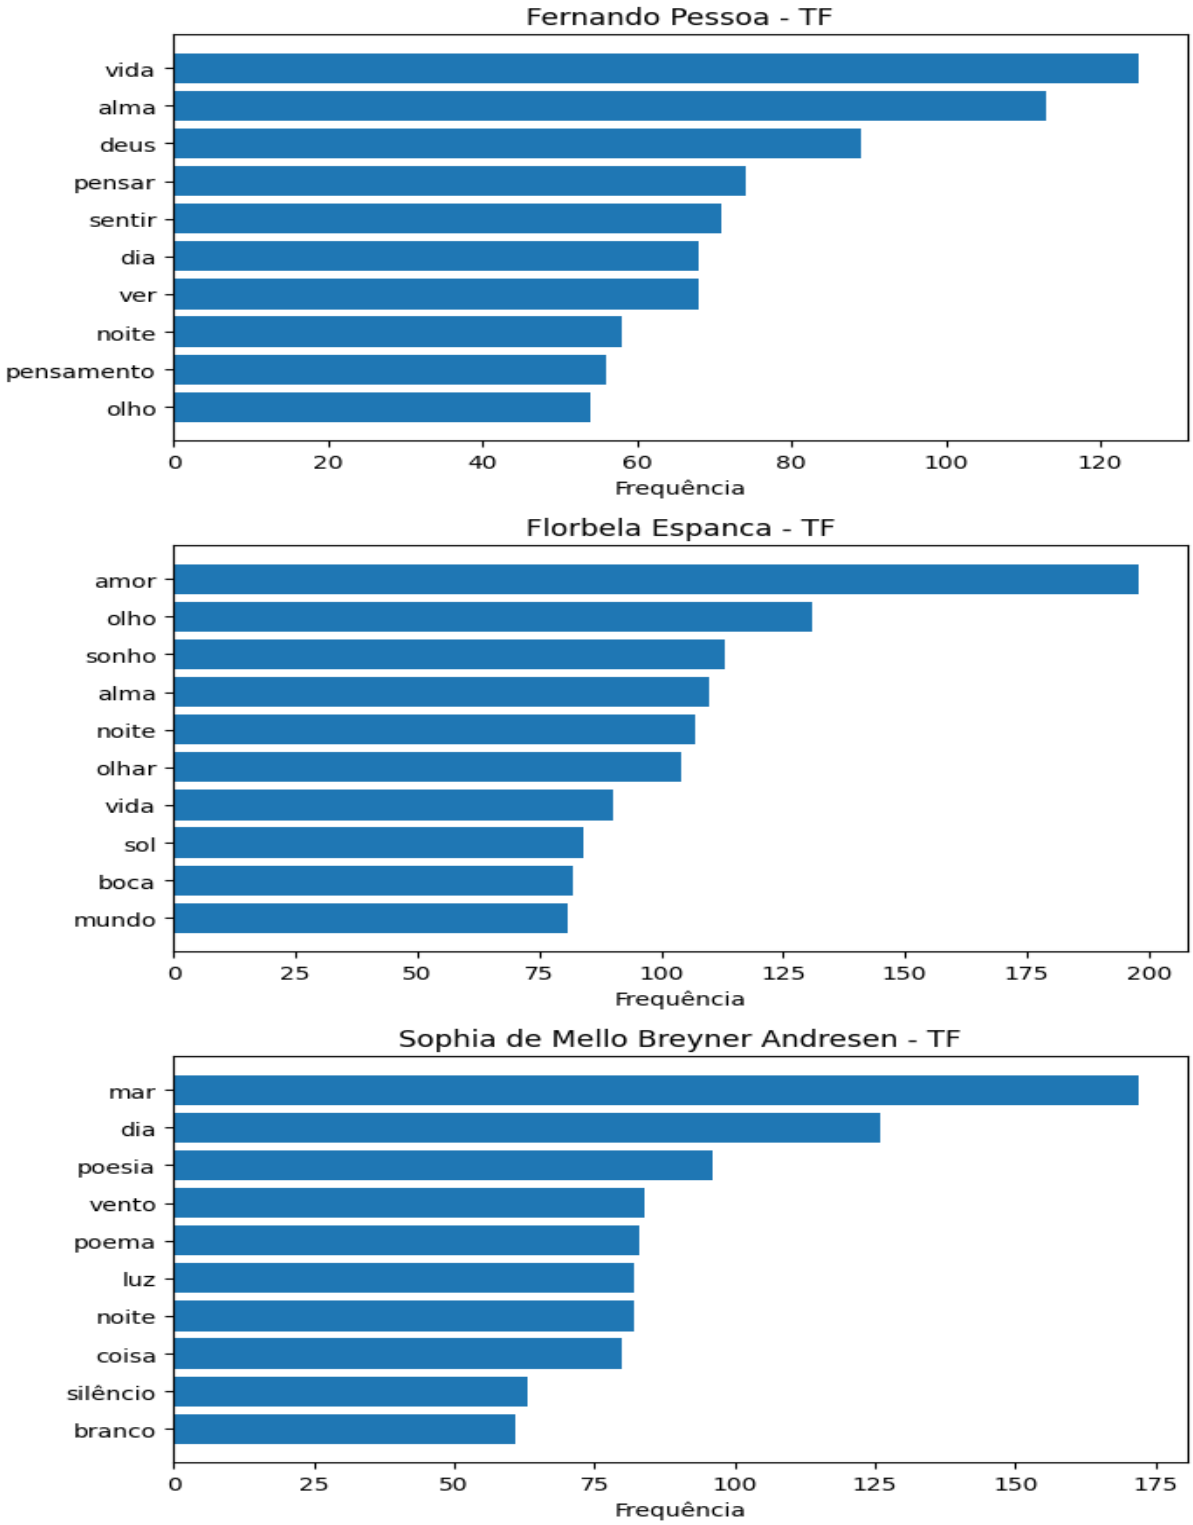

Fonte: Elaborado pelo autor (2026).

A análise das frequências lexicais evidencia diferenças temáticas claras entre os autores.

Em Fernando Pessoa, termos como “vida”, “alma”, “deus”, “pensar” e “sentir” indicam uma poesia voltada à reflexão existencial, à dualidade entre razão e emoção e à busca de sentido.

Na obra de Florbela Espanca, a recorrência de “amor”, “sonho”, “alma” e “noite” revela um lirismo intenso, marcado pelo subjetivismo, pela afetividade e por uma forte carga emocional.

Já em Sophia de Mello Breyner Andresen, palavras como “mar”, “dia”, “vento” e “luz” apontam para a valorização da natureza, da clareza e de uma poesia mais objetiva e contemplativa.

Assim, conclui-se que os dados quantitativos confirmam os traços estilísticos: reflexão filosófica em Pessoa, emocionalidade em Espanca e conexão com a natureza em Sophia.

3.3.2 Análise de importância dos termos

A análise com base no TF-IDF evidencia os termos mais distintivos de cada autor, destacando suas particularidades estilísticas.

Imagem 4 – Top 10 termos mais importantes por autor

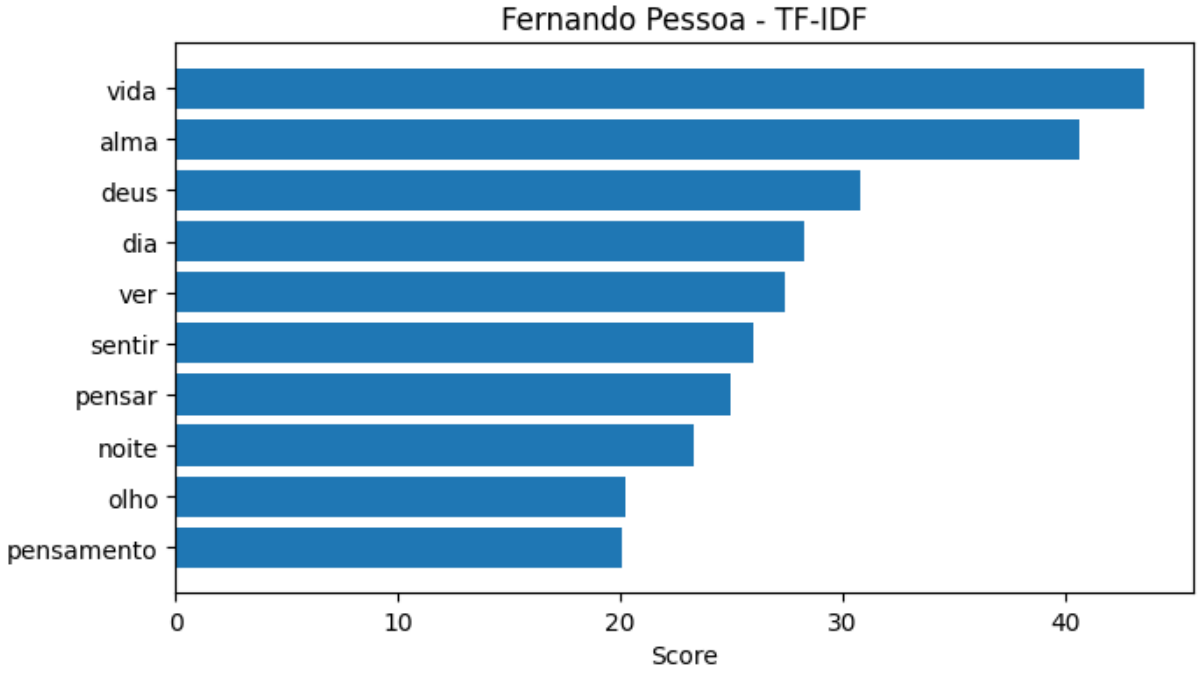
Fernando Pessoa - TF-IDF
vida
alma
deus
dia
ver
sentir
pensar
noite
olho
pensamento
0
10
20
30
40
Score

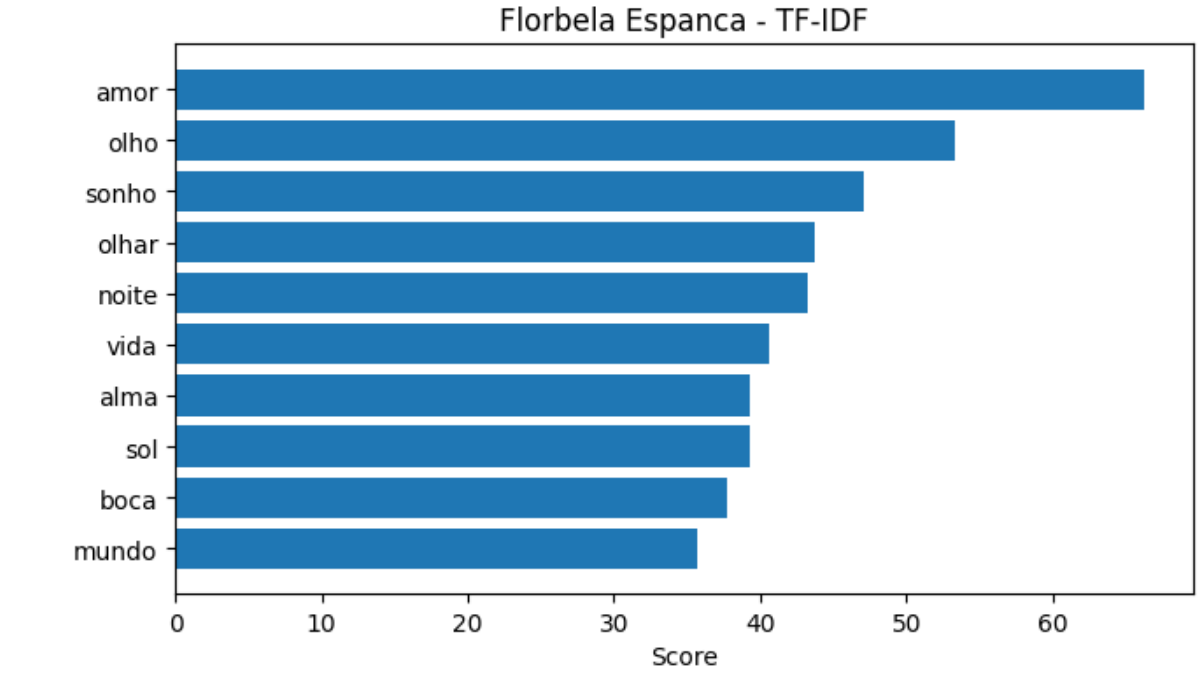
Florbela Espanca - TF-IDF
amor
olho
sonho
olhar
noite
vida
alma
sol
boca
mundo
0
10
20
30
40
50
60
Score

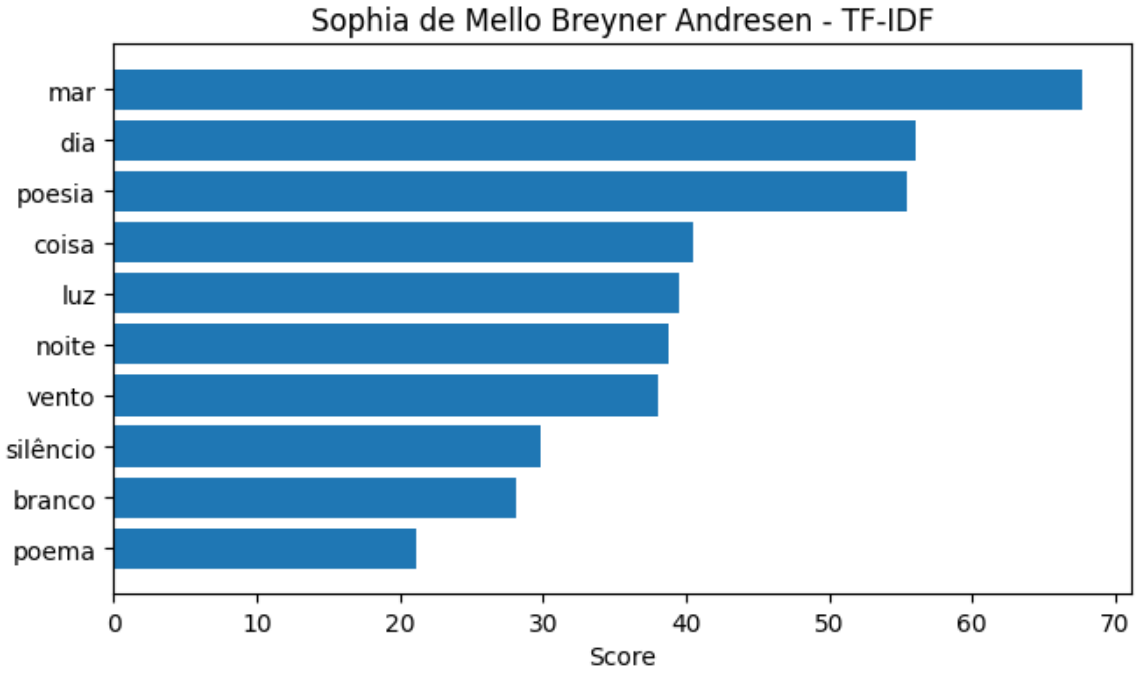
Sophia de Mello Breyner Andresen - TF-IDF
mar
dia
poesia
coisa
luz
noite
vento
silêncio
branco
poema
0
10
20
30
40
50
60
70
Score

Fonte: Elaborado pelo autor (2026)

Em Fernando Pessoa, palavras como “vida”, “alma” e “deus” mantêm destaque, indicando que, além de frequentes, são também centrais e distintivas em sua obra. Termos como “pensar” e “sentir” reforçam a dimensão reflexiva e filosófica, evidenciando uma linguagem voltada à introspecção e à busca de sentido existencial.

Na poesia de Florbela Espanca, “amor” apresenta o maior peso, confirmando-se como elemento central e característico de sua escrita. Outros termos como “olho”, “sonho” e “noite” também se destacam, sugerindo um campo semântico ligado à subjetividade, ao desejo e à expressão emocional intensa, aspectos marcantes de seu lirismo confessional.

Já em Sophia de Mello Breyner Andresen, termos como “mar”, “dia” e “poesia” apresentam maior relevância, indicando forte associação com a natureza e com a própria reflexão poética. Elementos como “luz”, “vento” e “silêncio” reforçam uma linguagem sensorial e contemplativa, alinhada à busca por clareza, harmonia e valores universais.

Assim, o TF-IDF confirma e aprofunda a análise anterior, ao evidenciar não apenas a frequência, mas a especificidade vocabular.

3.4.1 Comparação entre autores selecionados

A visualização por meio de word clouds, como demonstrados nas Imagem 5, 6 e 7 permitiu identificar visualmente as palavras mais presentes nos textos de cada autor. Nessas visualizações, o tamanho das palavras é proporcional à sua frequência ou relevância, facilitando a identificação de padrões linguísticos.

Imagem 5 – Nuvem de palavras – Fernando Pessoa

Fernando Pessoa
vida
alma
Deu
pensar
sentir
noite
ver
dia
sonho
pensamento
mundo
viver
coração
passar
horror
olho
luz
céu
ter
coisa
sol
hora
fazer
sonhar
chorar
abismo
esquecer
universo
sombra
ninguém
vejo
desejo
sol
porta
poder
acabar
falar
vento
eterno
levar
mar
amor
deixar
flor
frio
voltar
consciência
morte
palavra
mistério
outro
árvore
conhecer
mão
gente
buscar
ah
ficar
dar
cabeça
existir
terra
realidade
verdadeiro
próprio
morrer
corpo
alegria
saber
chegar
humano
ideia
esperança
torno
vontade
perder
espaço
verdade
criança
fundo
campo
querer
olhar
sinto
trazer
vago
sangue
ignorar
emoção
cristo
outrora
hoje
amar
vir
de um
erguer
medo
passado
desejar
focar
sorte
rio
infância
estrela
feliz
orgulho
sintar
nudo
sentimento
sentido
bastar
braço
santo
maneira
saudade
pena
som
bêbado
silêncio
inútil
abrir
achar
infinito
negro
esperar
ar
intimo
ilusão
mágoa
água
alegre
antigo
calor
passo
chão
verde
vaga
real
morto
nau
tédio
pra
certo
voz
brisa
cantar
ó
mar
levar
eterno
seguir
senão
chuva
valer
pequeno
pé
ti
rosa
quase
vicente
durar
sono
estranho
destino
alto
dizer
alguém
feira
consciência
razão
bom
falso
tornar
livro
enfim
ruído
casa
música
estrada
torno
igual
perder
chegar
canto
inda
cor
medo
homem
de ele
outrora
hoje
passado
desejar
focar
sorte
rio
esperança
vontade
infância
estrela
feliz
supremo
orgulho
sintar
nudo
sentimento
trazer
escrevo
nome
ignorar
emoção
cristo
sangue
erguer
de um
vir
amar
cor
medo
passado
desejar
focar
sorte
rio
esperança
vontade
ideia
torno
humano
saber
chegar
canto
inda
estrada
realidade
existir
terra
verdadeiro
próprio
morrer
corpo
alegria
coisa
perder
horror
voltar
frio
flor
deixar
amor
alguém
feira
consciência
fausto
apagar
correr
ouvir
dormir
cair
divino
dizer
estranho
destino
alto
quase
vicente
durar
sono
verso

Imagem 7 – Nuvem de palavras – Sophia de Mello

Fonte: Elaborado pelo autor (2026).

A análise das nuvens de palavras evidencia distinções claras entre os campos lexicais de cada autor. Em Fernando Pessoa, predominam termos associados à interioridade e à reflexão, sugerindo uma abordagem centrada no questionamento existencial e na fragmentação do eu. Já em Florbela Espanca, destacam-se palavras ligadas à afetividade e à intensidade emocional, indicando uma poesia marcada pelo lirismo subjetivo e pela expressão do desejo e da dor. Por sua vez, Sophia de Mello apresenta maior incidência de vocábulos relacionados à natureza e à percepção sensorial, refletindo uma escrita voltada à contemplação, à harmonia e à dimensão estética. Dessa forma, as nuvens de palavras reforçam as particularidades temáticas e estilísticas de cada autor, sem sobreposição significativa entre seus universos vocabulares.

3.4.2 *WordCloud* TF vs TF-IDF

A fim de uma comparação entre TF e TF-IDF foi selecionado o autor Fernando Pessoa para criação de um *wordcloud* com os dados de seus poemas.

Imagem 7 – Nuvem de palavras TF x TF-IDF

Fonte: Elaborado pelo autor (2026)

O WordCloud baseado em TF mostra as palavras mais frequentes no conjunto de poemas. Já no baseado em TF-IDF destaca palavras que são mais características de determinados poemas, reduzindo o peso de palavras muito comuns. Dessa forma, TF revela popularidade de termos, enquanto TF-IDF revela relevância contextual.

3.5 Análises de similaridade entre poemas

Utilizando a similaridade do cosseno aplicada aos vetores TF-IDF, permitiu identificar poemas semanticamente próximos dentro do corpus. Essa abordagem demonstrou que textos com vocabulário semelhante tendem a apresentar maior proximidade no espaço vetorial.

Imagem – 8 Análise de similaridade entre poemas

```
POEMA DE REFERÊNCIA: Fernando Pessoa
====================================================================
deixaste cair a liga porque não estava apertada... por muito que a gente diga a gente nunca diz nada....

POEMAS MAIS SIMILARES:

1. [0.6417] Florbela Espanca
   amar a quem nos despreza e sina que a gente tem; eu desprezo quem m'odeia e adoro quem me quer bem. ...

2. [0.5225] Sophia de Mello Breyner Andresen
   esta gente cujo rosto às vezes luminoso e outras vezes tosco ora me lembra escravos ora me lembra reis faz renascer meu gosto de luta e de combate con...
```

Fonte: Elaborado pelo autor (2026)

Como demonstrado na **Imagem 8,** a partir de um poema de referência de Fernando Pessoa, observou-se que os textos mais similares não se restringem ao mesmo autor, evidenciando aproximações temáticas entre diferentes estilos poéticos.

O poema mais semelhante pertence a Florbela Espanca, apresentando o maior índice de similaridade. Essa proximidade pode ser explicada pelo uso de um vocabulário comum ligado à subjetividade e às relações afetivas, como expressões de amor, desprezo e emoção, indicando convergência no campo semântico, apesar das diferenças estilísticas entre os autores.

Em seguida, aparece um poema de Sophia de Mello Breyner Andresen, cuja similaridade sugere pontos de contato no uso de termos relacionados à condição humana e à reflexão social. Embora sua obra seja frequentemente associada à natureza e à clareza, esse resultado demonstra que também há interseções temáticas com outros autores do corpus.

Dessa forma, a análise confirma que a similaridade vetorial baseada em TF-IDF é eficaz para identificar proximidades semânticas, revelando tanto relações entre diferentes autores quanto a diversidade interna de suas produções poéticas.

4. DISCUSSÃO

4.1 Interpretação dos resultados

Os resultados obtidos demonstram que técnicas de Processamento de Linguagem Natural podem ser utilizadas de forma eficaz para explorar padrões linguísticos em textos literários. Mesmo em um corpus composto por poemas, que frequentemente apresentam linguagem figurada e estruturas não convencionais, foi possível identificar tendências e diferenças estilísticas entre autores.

4.2 Comparação entre TF e TF-IDF

A comparação entre TF e TF-IDF mostrou diferenças importantes na interpretação dos dados. Enquanto o TF destaca palavras mais frequentes no corpus, o TF-IDF consegue identificar termos mais distintivos de determinados poemas ou autores, proporcionando uma visão mais aprofundada do conteúdo semântico.

4.3 Aplicação de *stemming* e lematização

A aplicação das técnicas mostrou impactos relevantes na análise textual. O *stemming* facilita a redução de variações morfológicas, mas pode gerar radicais que não correspondem a palavras reais da língua. Já a lematização preserva formas linguísticas válidas, tornando os resultados mais interpretáveis, sendo uma melhor escolha para análise semântica.

4.4 Limitações do estudo

O estudo apresentou limitações relacionadas às ferramentas e ao próprio corpus analisado. No caso da biblioteca NLTK, observou-se limitação no suporte a modelos adequados para a língua portuguesa, o que comprometeu a precisão em tarefas de classificação gramatical. Esse resultado evidencia a dependência de modelos específicos para cada idioma, sendo inadequado o uso de modelos treinados em contextos linguísticos distintos.

Outra limitação identificada se refere à composição do conjunto de dados, no qual foram encontrados termos em diferentes idiomas, sem separação prévia. Esse fator pode ter influenciado os resultados de frequência e comprometido parcialmente a análise.

Outro aspecto importante observado foi o desbalanceamento do *dataset*. Autores com maior quantidade de poemas tendem a influenciar mais as estatísticas globais do corpus. Por esse motivo, a seleção de autores específicos e limitação de poemas para análise comparativa foi uma estratégia importante para reduzir esse efeito.

4.4 Implicações práticas

Os achados deste estudo possuem implicações relevantes para o desenvolvimento de aplicações em Processamento de Linguagem Natural. A escolha da técnica de normalização deve considerar o objetivo da aplicação, equilibrando desempenho e precisão linguística.

Em cenários que demandam rapidez e processamento de grandes volumes de dados, o uso de *stemming* pode ser mais adequado. Por outro lado, aplicações que exigem maior interpretação semântica, como sistemas de recomendação, análise de sentimentos ou *chatbots*, tendem a se beneficiar do uso de lematização.

Além disso, os resultados reforçam a importância da etapa de pré-processamento como fator determinante para a qualidade das análises, destacando a necessidade de adequação das ferramentas ao idioma e ao tipo de corpus utilizado.

5. CONCLUSÃO

Este trabalho demonstrou a aplicação de técnicas de Processamento de Linguagem Natural na análise de poemas em língua portuguesa. A partir do uso de métodos de pré-processamento, vetorização textual e análise estatística, foi possível explorar padrões linguísticos presentes no corpus e identificar diferenças estilísticas entre autores.

As técnicas de TF e TF-IDF mostraram-se eficazes para identificar termos relevantes nos textos, enquanto as etapas de *stemming* e lematização contribuíram para a normalização das palavras e melhoria da análise textual.

Além disso, o uso de visualizações como *wordclouds* e a análise de similaridade entre poemas permitiram interpretar os resultados de forma mais intuitiva.

Como aprendizado principal, o trabalho evidencia que técnicas de mineração de texto podem ser aplicadas não apenas em documentos informativos, mas também em textos literários, oferecendo novas perspectivas para a análise de obras e estilos de diferentes autores.