

TRABALHO FINAL

[Título do Projeto]

Agente de Análise Exploratória de Dados em Linguagem Natural

Dataset: [Nome do Dataset Escolhido]

Grupo: [Nome 1] | [Nome 2] | [Nome 3] | [Nome 4]

Tecnologia em Ciência de Dados — 5º Semestre

Fatec Ourinhos — [Data da Apresentação]

Agenda

1. O problema e a motivação
2. O dataset escolhido
3. Arquitetura do agente
4. Ferramentas implementadas
5. Demonstração ao vivo
6. Conjunto de avaliação (benchmark)
7. Resultados quantitativos
8. Análise de trajetórias e erros
9. Discussão crítica
10. Conclusões e trabalhos futuros



 **Dica:** 15 minutos no total — cerca de 1,5 min por slide. Ensaie pelo menos 2 vezes antes da apresentação.

1. O problema e a motivação

Pergunta orientadora

[Escreva aqui a pergunta que o seu agente é capaz de responder. Ex.: "O agente consegue responder, sobre qualquer CSV, perguntas analíticas em português que envolvam múltiplos passos de pandas?"]

Por que esse problema importa?

- [Razão 1 — ex.: tornar análise de dados acessível a quem não programa]
- [Razão 2 — ex.: comparar abordagem clássica vs. abordagem agêntica]
- [Razão 3 — ex.: explorar limites de raciocínio multi-passo de LLMs]



Dica: Resista à tentação de explicar o que é LLM/agente. Foque no SEU problema e no SEU dataset.

2. O dataset escolhido

Sobre os dados

Nome: [ex.: Adult Income, UCI]

Origem: [fonte / link]

Tamanho: [N linhas × M colunas]

Período: [se aplicável]

Pré-processamento: [o que vocês fizeram antes de usar]

Colunas e tipos

Coluna	Tipo	Exemplo
[col_1]	[num/cat]	[valor]
[col_2]	[num/cat]	[valor]
[col_3]	[num/cat]	[valor]
[col_4]	[num/cat]	[valor]
[col_5]	[num/cat]	[valor]

 **Dica:** Mostre 1 gráfico exploratório do dataset se sobrar espaço. Imagem vale mais que descrição textual.

3. Arquitetura do agente



Componentes principais

Orquestrador: [framework usado — ex.: function calling nativo, LangChain, Pydantic AI]

LLM: [modelo escolhido + justificativa: custo, latência, qualidade]

Tools: [N tools implementadas, sendo X obrigatórias e Y extras]

4. Ferramentas implementadas

Ferramenta	Tipo	O que faz
listar_colunas	Obrigatória	Nomes e tipos de cada coluna
descrever_dados	Obrigatória	describe() estendido
contar_valores	Obrigatória	Distribuição de uma coluna
filtrar	Obrigatória	Subconjunto + estatísticas
agrupar_e_agregar	Obrigatória	groupby + agg
correlacao	Obrigatória	Pearson / Spearman
detectar_outliers	Obrigatória	IQR ou z-score
gerar_grafico	Obrigatória	Hist / boxplot / scatter / barplot
[tool_extra_1]	★ Extra	[descrição do que faz e por que adicionaram]

💡 **Dica:** Destaque em laranja as tools extras que vocês criaram — é onde o bônus da rubrica entra.

5


DEMONSTRAÇÃO AO VIVO

Roteiro da demo (3-5 min):

1. Mostrar a CLI / Streamlit já aberto com o dataset carregado
2. Pergunta simples (1 tool) → mostrar a trajetória nos logs
3. Pergunta analítica multi-tool → destacar o raciocínio do agente
4. Pergunta ambígua → mostrar o comportamento de recusa

6. Conjunto de avaliação (benchmark)

Composição do benchmark.json



■ Factuals simples (10) ■ Analíticas multi-tool (15) ■ Ambíguas/inválidas (5)

Exemplos do nosso benchmark

Factual: "[pergunta simples do seu dataset]"

Analítica: "[pergunta multi-tool do seu dataset]"

Ambígua: "[pergunta ambígua/inválida]"

💡 **Dica:** Mostre 1 exemplo de pergunta com gabarito calculado em pandas — prova rigor metodológico.

7. Resultados quantitativos

[XX%]

Acurácia geral

[XX%]

Taxa de execução
bem-sucedida


[X.X]

Tool calls
por pergunta (média)

[X.Xs]

Latência média
por pergunta

Acurácia por tipo de pergunta



8. Análise de trajetórias e erros

✓ Trajetória de sucesso

Pergunta: "[pergunta analítica]"

Passos do agente:

1. listar_colunas() → identificou cols relevantes
2. filtrar(...) → aplicou recorte
3. agrupar_e_agregar(...) → calculou média

Resposta: [valor] ✓ confere com gabarito

✗ Análise de erro

Pergunta: "[pergunta que falhou]"

O que o agente fez:

[descrição da trajetória errada]

Hipótese da causa:

[ex.: prompt ambíguo, tool faltando, alucinação de coluna inexistente]

9. Discussão crítica



Custo

Total gasto no benchmark: [US\$ X,XX].
Custo médio por pergunta: [US\$ 0,00X].
Viável em escala? [sim/não, por quê]



Latência

Resposta simples: [Xs].
Resposta multi-tool: [Xs].
Gargalo principal: [API / processamento / outro]



Alucinação

Casos detectados: [X de 30].
Tipo mais comum: [coluna inexistente / valor inventado / outro].
Mitigação tentada: [...]



Limitações

[O que o agente NÃO consegue fazer?]
[Que tipo de pergunta sempre falha?]



Ética e viés

[O dataset tem viés? Como isso afeta as respostas?]
[Riscos de uso indevido do agente?]



Trabalhos futuros

[Que melhorias trariam mais impacto?]
[Que próximo passo natural?]

10. Conclusões

O que conseguimos demonstrar

1. [Conclusão 1 — relacionada à pergunta orientadora]
2. [Conclusão 2 — sobre o desempenho do agente]
3. [Conclusão 3 — sobre o que aprenderam no processo]

Principal lição técnica

"[Uma frase forte que resuma o que vocês descobriram sobre construir agentes em contextos limitados. Esta frase deve ser memorável para a banca.]"

 **Dica:** Não termine com 'Obrigado'. Termine com o aprendizado mais importante — é o que fica na cabeça da banca.

Referências

[Autor]. Título do artigo / documentação / livro. Ano. Disponível em: <link>

[Autor]. Título do artigo / documentação / livro. Ano. Disponível em: <link>

Documentação oficial: [link para a API LLM usada — Anthropic / OpenAI / Google]

Dataset: [link de onde foi obtido o dataset]

Repositório do projeto: [link público do GitHub/GitLab]

Perguntas?

Repositório do projeto

[[github.com/seu-usuario/seu-repo](#)]

Grupo: [Nome 1] | [Nome 2] | [Nome 3] | [Nome 4]